## Implémentez un modèle de scoring

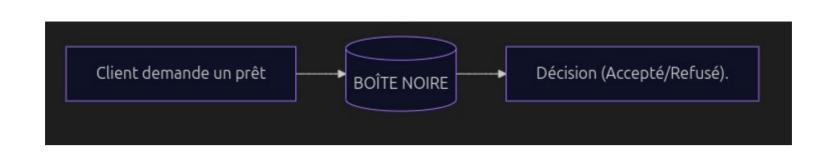


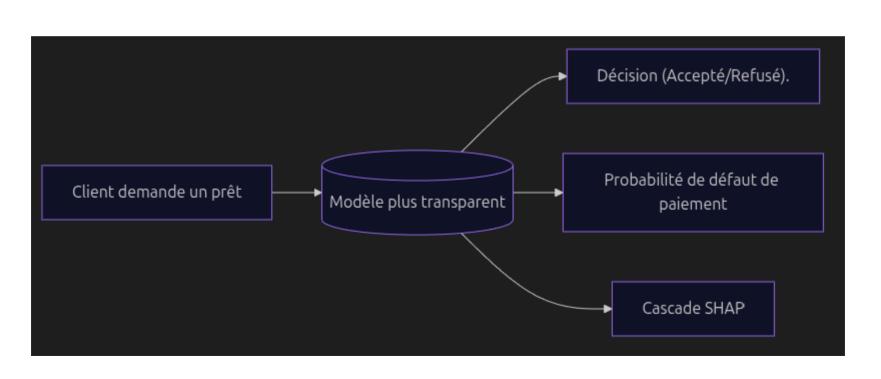
**GHOUL Nadir** 

OpenClassrooms

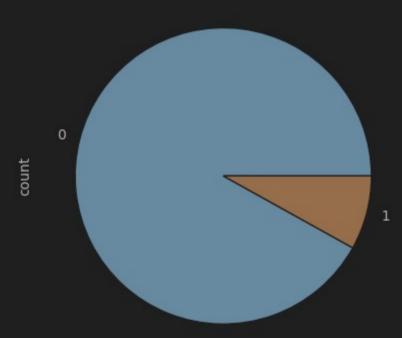
## Sommaire

- Contexte et Problématique Métier
- Démarche de Modélisation
- Suivi des Expériences avec MLflow
- Résultats et Interprétabilité du Modèle
- Pipeline de Déploiement Continu (CI/CD)
- Analyse du Data Drift
- Démonstration de l'API
- Conclusion et Perspectives





Répartition des cibles (0=paiement complet, 1=retards de paiement)



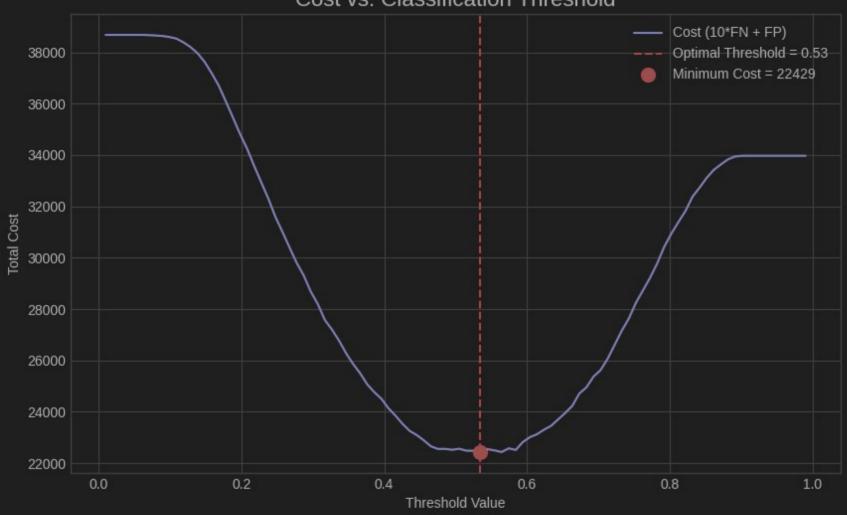
## Déséquilibre dataset

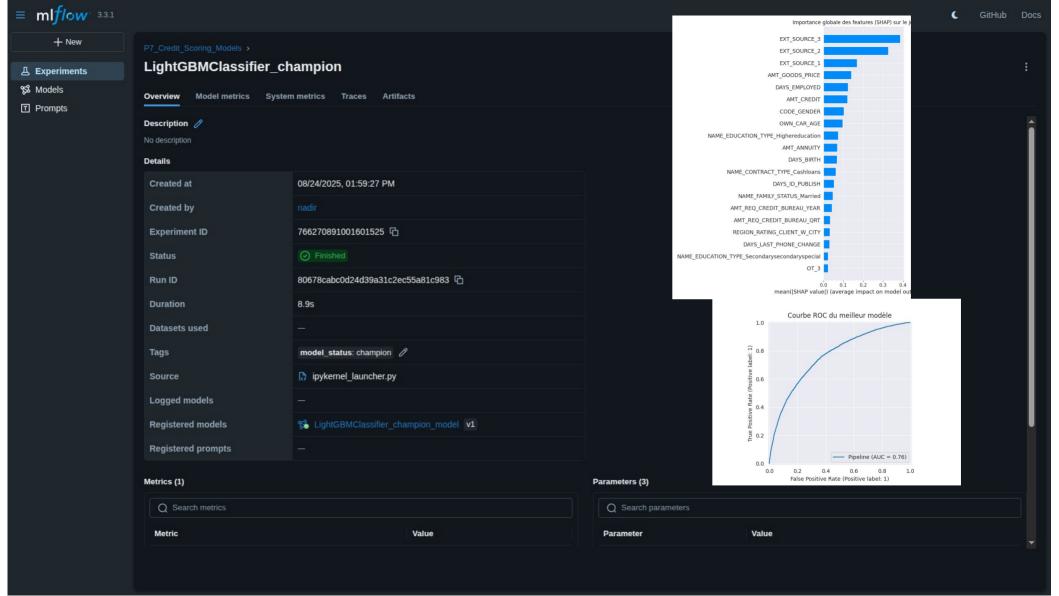
- Déséquilibre dataset
  - Cause: 92% payent à temps
  - Symptôme: 92% accuracy pour autorisation systématique
  - Solutions:
    - Undersampling => Réduction de 84%
    - Oversampling => SMOTE => Grandissement de 48%
      - Nécéssite une imputation des données
      - Données synthétiques
    - Class weighting => Aucun changement du dataset

## Déséquilibre métier

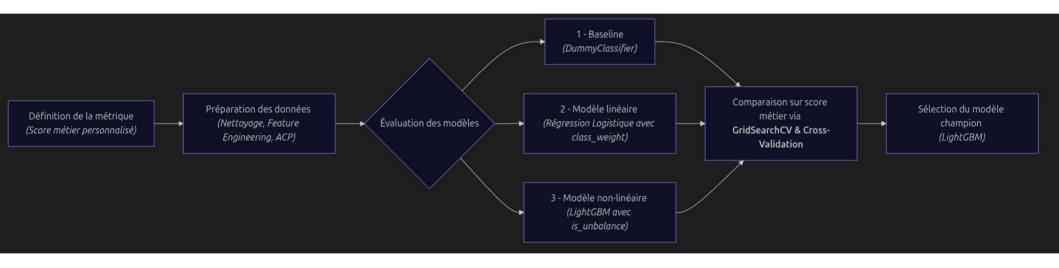
- Déséquilibre métier
  - Cause: cost(FN) ~ 10 \* cost(FP)
  - Symptôme: 9 FN traités comme meilleur que 10 FP
  - Solution: Score métier
    - Coût total = 10 \* Faux Négatifs + 1 \* Faux Positifs.

#### Cost vs. Classification Threshold



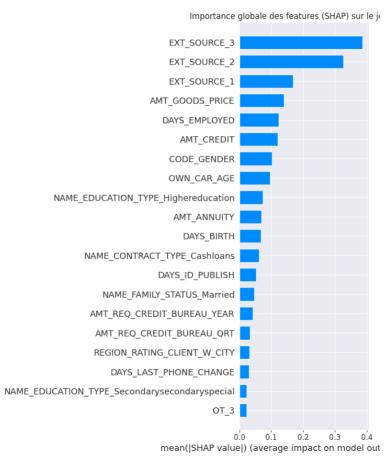


# Stratégie de Modélisation et Optimisation



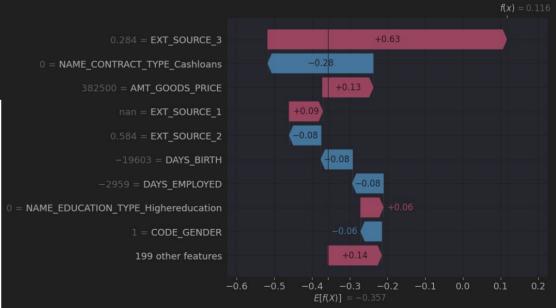
### Résultats et Choix du Modèle Final

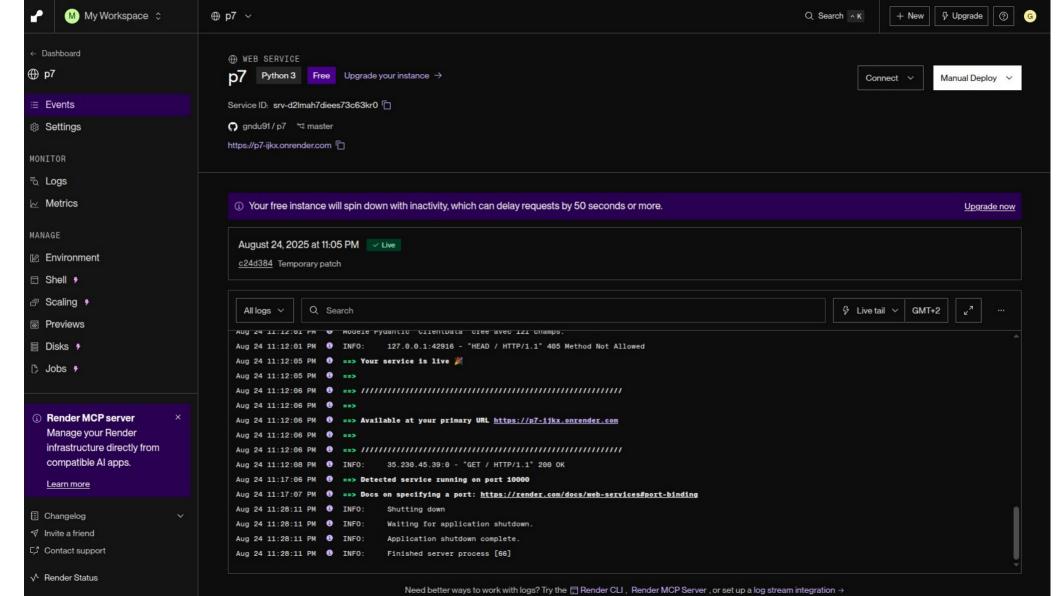
# Interprétabilité Globale (Feature Importance)



Comparaison de deux clients







#### Dataset Drift

Dataset Drift is NOT detected. Dataset drift detection threshold is 0.5

121 Columns		9 Drifted Columns		0.0744 Share of Drifted Columns					
Data Drift Summary									
Drif	Drift is detected for 7.438% of columns (9 out of 121).								
							Q Search		
	Column	Туре	Reference Distribution	Current Distribution	Data Drift	Stat Test	Drift Score		
	AMT_REQ_CREDIT_BUREAU_QRT	num		<b>I</b>	Detected	Wasserstein distance (normed)	0.473426		
	AMT_REQ_CREDIT_BUREAU_MON	num			Detected	Wasserstein distance (normed)	0.287609		
	AMT_GOODS_PRICE	num	<b>1</b>	ili	Detected	Wasserstein distance (normed)	0.200103		
	AMT_CREDIT	num	<b>11</b>	111	Detected	Wasserstein distance (normed)	0.197557		
	AMT_ANNUITY	num		id	Detected	Wasserstein distance (normed)	0.164792		
	AMT_REQ_CREDIT_BUREAU_WEEK	num			Detected	Wasserstein distance (normed)	0.154747		
	NAME_CONTRACT_TYPE	cat			Detected	Jensen-Shannon distance	0.149114		
	DAYS_LAST_PHONE_CHANGE	num			Detected	Wasserstein distance (normed)	0.140915		
	FLAG_EMAIL	cat			Detected	Jensen-Shannon distance	0.124207		
	AMT_REQ_CREDIT_BUREAU_YEAR	num	<b>L</b>	l	Not Detected	Wasserstein distance (normed)	0.072723		
	Rows per page: 10 rows ▼  〈 〈 1.10 of 121 〉 〉								